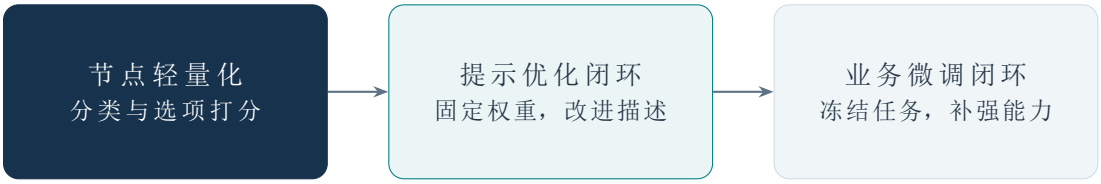
技术方案 / 参赛申请

让业务判断更轻，让优化持续发生

业务决策模型治理与效能优化方案

规范模型选用、效果评估与持续改进，在保障业务质量的同时控制处理时延与成本



方案主张

保留必要的内容生成，将边界清晰的判断任务交给合适的决策后端；通过真实错误驱动的两条离线闭环，形成可评测、可追溯、可回退的持续优化机制。

评测说明：方案收益以真实业务场景的实测数据和验收结果为准。

方案速览

一句话理解

用更适合判断任务的推理方式承接业务节点，在质量达标的前提下减少生成开销；再以提示优化和可选微调持续提高可靠承接能力。

为什么做

智能助理中的意图分类、改写判断和证据筛选，往往只需输出类别、是非或分数，却可能消耗一次完整的生成式调用。

从哪里开始

首先验证意图识别，重点区分消费者退款、商户结算和支付状态；问题改写与检索片段筛选作为扩展场景。

如何持续改进

先诊断输入、标签与策略问题；描述不清时优化提示，领域能力不足且训练条件具备时再比较微调。两条闭环均在线下运行。

怎样判断有效

先满足预先约定的质量约束，再比较完整链路时延与每成功任务总成本。新增决策、回退、运维和离线优化摊销均计入成本。

目录

方案速览 **i**

1 背景与目标 **1**

2 具体使用场景 **1**

2.1 主场景：智能助理意图识别 1

2.2 扩展场景：是否需要问题改写 2

2.3 扩展场景：RAG 检索片段筛选 3

3 降本提速机制与预期成效 **4**

3.1 三条降本提速路径 4

3.2 同一业务问题的使用前后对比 4

3.3 双闭环 RSI 如何支持持续降本 5

3.4 预期成效与参赛验证成果 5

4 总体架构 **6**

5 核心实现方案 **7**

5.1 业务节点如何替换 7

5.2 提示优化闭环如何运行 8

5.3 业务微调闭环如何运行 8

5.4 两条闭环如何协同 9

5.5 评测、版本与运行保障 9

6 效果验证方案 **10**

6.1 验证要回答的问题 10

6.2 测试数据如何准备 10

6.3 离线同题对照 10

6.4 完整业务链路验证 11

6.5 成本口径与验收结论 11

7 预期价值与适用边界 **12**

1 背景与目标

智能助理的一条业务链路，往往需要先识别用户意图，再判断是否改写问题、检索材料是否有用，最后生成回答。其中不少节点只需输出一个类别、是非结果或分数，却仍调用通用生成式大模型。

例如，用户问“退款已经申请了，怎么还没到账?”，意图识别节点只需要返回“退款进度查询”。当这类判断频繁出现或多个节点串联时，推理费用与等待时间会不断累积。与此同时，类别描述和提示词主要靠人工调整，业务错误尚未形成统一的优化反馈。

本方案将适合的判断节点交给决策模型处理，并建立提示优化、业务微调两条离线闭环。目标是在业务质量达标的前提下，降低完整任务的总成本与时延，同时形成可复用的节点优化能力。

项目围绕“用决策推理替代生成式判断、减少不必要的生成调用、减少回答模型的冗余输入”三条路径开展优化；通过双闭环 RSI 持续改善决策模型的业务适配能力，形成可对照、可验证、可回退的降本提速方案。

2 具体使用场景

2.1 主场景：智能助理意图识别

用户问题进入智能助理后，系统需要识别其业务诉求，再进入退款查询、商户结算查询等对应流程。决策模型承接的是路由前的判断，不负责查询业务数据，也不直接执行业务操作。

表 1:用户意图识别示例及下游处理

用户表达示例	期望识别结果	后续处理
“退款已经申请了，怎么还没到账?”	退款进度查询	进入退款查询流程
“今天的收款为什么还没结算?”	商户结算查询	进入结算查询流程
“这笔订单到底付成功没有?”	支付状态查询	进入支付状态查询流程
前文说“我申请了退款”，当前问“什么时候到?”	结合前文识别退款进度查询	使用必要的对话上下文
没有前文，只问“什么时候到?”	信息不足，需要澄清	询问所指业务
问题明确，但不属于支持范围	未知意图	转原有兜底流程

“退款到账”与“结算到账”都有到账概念，但业务对象不同，是需要重点验证的混淆边界。多意图输入也应明确采用多标签、逐项判断或澄清，不能强行套用单选分类。

输入：当前用户问题、分类必需的对话上下文、经授权的结构化信息。

输出：类别 ID、各选项原始概率/分数、接受/回退状态、版本与耗时。

提示优化应更清晰表达这种差异，而非把任一类别扩展成” 所有到账问题” 来提高局部分数。

替换前后链路：

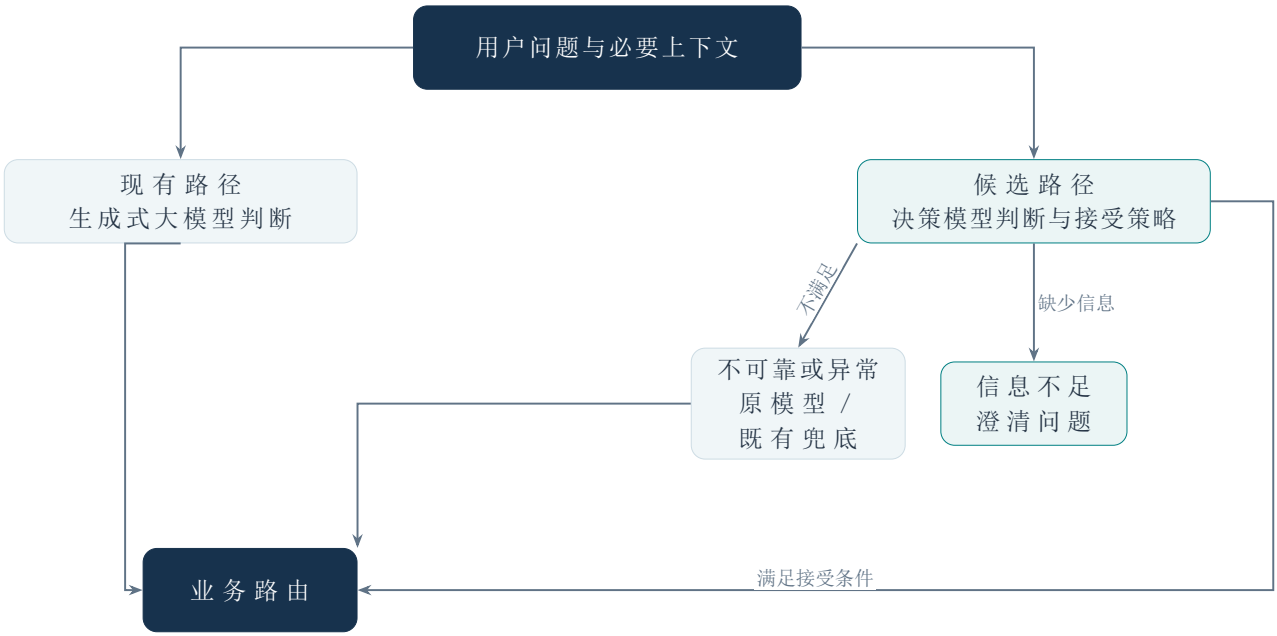


图 1　意图识别替换路径：接受、澄清与回退分别处理

图中两条路径用于比较现有与候选方案；正式运行时按批准配置选择路径。候选方案需验证完整路由结果，不能只展示模型返回的类别。

场景应用举例（原本如何 → 用本方案预期如何）

以” 退款已经申请了，怎么还没到账？ ” 为例：

表 2: 意图识别流程优化前后对照

环节	原本流程	用本方案后（预期）
判断方式	调用通用生成式大模型，让模型输出类别名称	调用轻量决策模型，直接输出类别 ID 与各选项概率
耗时	生成式推理串联，等待首 token 与完整文本	采用支持分类或选项打分的后端，预期减少生成式解码开销，实际时延待测
成本	生成式调用按实际输入、输出及计费规则核算，高频调用累积成本高	按所选后端的实际计费或部署成本核算，验证单次决策费用是否下降
易混淆处理	依赖人工调整提示词区分” 退款到账” 与” 结算到账”，调整滞后	离线提示优化迭代类别描述，经评测与审批后发布优化版本
未知/澄清	依赖现有接受与兜底策略，实际处理方式需先核查	置信不足时进入 CLARIFY 或 FALLBACK，回到原流程，不强行归类

2.2　扩展场景：是否需要问题改写

在多轮问答中，用户说 “那什么时候到?”，系统可能需要结合前文补全为 “已申请的退款预计什么时候到账?”，再进行检索。

决策模型只判断是否进入改写路径；需要改写时，仍由生成模型产出新问题。对于已经完整明确的问题，可直接检索，减少不必要的生成调用。

该场景的价值取决于检索和回答是否改善。漏掉必要改写可能损害召回，多做改写会增加成本，因此不能单纯追求降低改写率。

评测同时比较原始与改写后检索的关键证据和最终回答质量，依据漏改写的质量损失与多改写的额外费用设定策略。

场景应用举例

以多轮对话中”那笔呢？”（指代前文某笔交易）为例：

表 3:问题改写场景优化前后对照

环节	原本流程	用本方案后（预期）
改写触发	在默认改写的流程中，每条问题都送生成式大模型改写，再检索	决策模型先判断是否需要改写，确认无需改写的完整问题直接检索
成本	每次调用都付出改写生成费用，包括无需改写的简单问题	仅需改写的问题才调用大模型，预期改写调用占比下降、总成本降低
风险	若缺少统一评测，漏改写与多改写主要依靠人工经验权衡	用”必要改写召回 / 多余改写率”量化，按质量损失与额外费用设定阈值
回退	需核查现有流程是否具备检索失败后的补救机制	判错可经反馈回流进入错误分析池，驱动提示或策略迭代

2.3 扩展场景：RAG 检索片段筛选

检索返回多段退款规则、商户结算说明和产品材料后，决策模型判断哪些片段对当前问题有帮助，再交给回答模型。

沿用已有分块与检索，先做”是否对回答有帮助”。

输入应包含问题、片段及必要来源和上下文；关键证据、例外条款和冲突材料需保守保留。主题相关不等于能支撑答案，更不等于答案正确。

此场景应与已有 reranker 对照。如果专用 reranker 在同等条件下更好、更便宜，就保留它。项目不要求所有节点都使用同一类模型。

场景应用举例

以用户问”退款多久到账”，检索返回 5 个候选片段为例：

表 4: 检索片段筛选场景优化前后对照

环节	原本流程	用本方案后（预期）
片段筛选	5 个片段全部送入生成式大模型上下文，由模型自行取舍	决策模型先标注”是否对回答有帮助”，仅保留关键证据片段
上下文成本	冗余片段增加输入 token，推高生成费用与时延	裁剪后输入缩短，预期减少回答模型输入费用；完整链路时延需扣除筛选开销后验证

续下页

环节	原本流程	用本方案后（预期）
关键证据	例外条款、冲突信息可能被模型忽略	保守保留例外与冲突片段，减少漏答风险
对照	若缺少独立评测，则难以判断裁剪是否损害质量	用” 证据召回 / 误删 / 保留比例” 量化，与现有 reranker 公平对照后择优

3 降本提速机制与预期成效

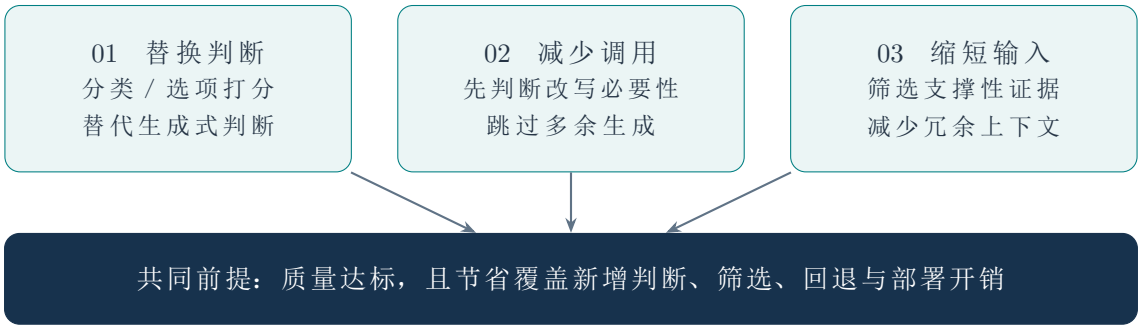


图 2 三条收益路径可以独立采用，净收益必须按完整任务核算

3.1 三条降本提速路径

本项目不以减少必要的业务处理换取成本下降，而是将“需要生成内容”与“只需作出判断”的任务分开。以下收益均以业务质量达标为前提；原有调用方式和费用应先通过实际日志确认，不将示例流程直接视为现网事实。

表 5:三条降本提速路径及生效条件

优化路径	原有资源消耗	本方案如何减少消耗	提速来源与生效条件
替换昂贵判断	为获取一个类别或是非结果，调用通用生成式大模型	对适合的节点采用分类或选项打分后端，直接返回结构化决策，替代原生成式判断调用	减少生成式解码及相关处理；只有候选后端的实际推理、部署和回退开销更低时才有净收益
减少生成调用	默认改写流程对无需改写的问题也执行一次生成	先判断是否需要改写，明确完整的问题跳过改写生成，必要改写仍保留	无需改写的请求少等待一次生成；节省必须覆盖新增判断开销，且不能损害必要改写的召回
缩短生成输入	冗余检索片段进入回答模型，增加输入 token	筛选与问题有关且能支撑回答的证据，保留必要的例外和冲突材料，减少冗余上下文	降低输入处理量及相应费用；筛选本身也消耗资源，实际净时延受后端、批处理和缓存影响

三条路径可以独立采用，不要求同时替换所有节点。输出更短不等于模型一定更小或更快；若所选后端仍需生成文本，则应按实际生成过程核算，不将其视为无生成开销的分类器。

3.2 同一业务问题的使用前后对比

以“退款已经申请了，怎么还没到账？”为例，演示一条包含意图识别、问题改写、规则检索和回答生成的链路。假设原流程分别调用生成模型完成意图识别、默认改写和最终回答，并将检索返回

的 5 个片段全部送入回答模型。实际业务查询等其他必要步骤保持不变。

以下数字仅用于说明链路变化，不是实测结果，也不是对现网调用次数的确认。

表 6:示例业务链路优化前后对照

环节	使用前：示例基线	使用后：预期路径
意图识别	1 次生成式调用，输出退款进度查询类别	决策模型判断；满足接受策略后进入同一业务流程，不再执行原生成式分类调用
问题改写	1 次生成式调用，对问题进行改写	决策模型确认问题已完整明确后跳过改写；需要改写时仍调用生成模型
检索上下文	5 个检索片段全部进入回答模型	假设经评估其中 3 个已覆盖必要证据，则保留这 3 个；证据不足时不得机械裁剪
回答生成	1 次生成式调用，读取全部候选片段	仍保留 1 次回答生成调用，读取筛选后的证据
调用结构	共 3 次生成式调用	在判断可靠且无需改写的示例路径中，变为 1 次生成式调用，另增加决策与筛选开销

这一示例体现的是：**保留必要的回答生成，把用于判断的生成调用替换掉，把不必要的改写调用省下来，把冗余证据输入减下来。**片段筛选的调用次数取决于后端与批处理方式，不假定多个片段可零开销或一次完成。

生成式调用从 3 次变为 1 次，不等于总费用或完整链路时延必然下降三分之二。问题需要改写、发生回退或筛选开销过大时，收益会缩小，甚至不成立；最终按完整任务的实际费用与时延判断。

3.3 双闭环 RSI 如何支持持续降本

仅替换模型可能因业务表达识别不准而增加误判、澄清和回退，抵消轻量化收益。双闭环 RSI 的作用，是在固定业务含义和质量约束下，持续改善低成本模型承接判断任务的能力，而不是在线上增加一轮自优化操作。

- **提示优化闭环：**针对“退款到账”与“结算到账”等混淆，优化类别描述、排除说明和示例，争取在不训练模型的情况下改善判断质量。
- **业务微调闭环：**当描述已清晰、输入与标签已修复，仍存在稳定的领域误判时，通过审核后的业务数据补强识别能力，并与未微调版本对照。

只有在接受部分错误率满足约束的前提下，提高自动接受覆盖率、减少不必要的回退才算有效改善，不能靠降低接受标准获得表面上的节省。两条闭环都在线下运行，候选通过评测和审批后才发布；标注、搜索、训练及验收费用按约定周期摊销，不能从收益核算中删除。

3.4 预期成效与参赛验证成果

项目预期实现“业务质量达标、完整任务成本下降、完整链路时延缩短”，并分别验证直接替换、提示优化和业务微调的贡献。当前文档未提供实测数据，以下为待验证目标，不作为已实现成果。

表 7:项目预期成效与验收关注点

维度	使用前需记录的基线	使用后预期成效	验收关注点
业务质量	当前路由正确率、关键类别召回和最终回答质量	在预先约定的允许退化范围内达标，关键业务指标不突破下限	不以漏改写、误删证据或强行分类换取节省
完整任务成本	当前每成功任务总成本及费用构成	将新增决策、回退、部署运维与离线优化摊销一并计入后，成本仍下降	区分节点费用下降与完整任务净节省
响应效率	相同负载下的完整链路 p50/p95、吞吐和超时率	完整链路 p95 缩短，超时率不恶化，并报告其他性能指标	不能只用某个决策节点的加速代表用户整体体验
优化可持续性	当前模型、提示、数据与人工调整记录	形成可复现的提示优化与可选微调实验，发布可追溯、可回退的版本	无有效增量时保留原版本，不强行上线候选

成本降幅按“（基线每成功任务总成本－优化后每成功任务总成本）÷ 基线每成功任务总成本”计算；时延降幅按相同口径的完整链路 p95 比较。两者分别报告，不能用生成调用次数或输入 token 的降幅替代。具体质量门槛和验收目标在查看候选结果前确定，详细数据划分、测试条件及结果表见第六章。

参赛验证拟形成三类成果：可运行的首个意图识别试点、可复现的双闭环优化与对照实验、包含质量和完整成本时延的前后对比报告。扩展场景按实际验证进度分别呈现；未完成部分明确标注为计划或待验证，不与已完成成果混写。

4 总体架构

系统分为线上决策和离线优化两部分。线上只加载经过批准的版本，离线负责分析错误、生成候选并验证改进；两者通过版本包连接。

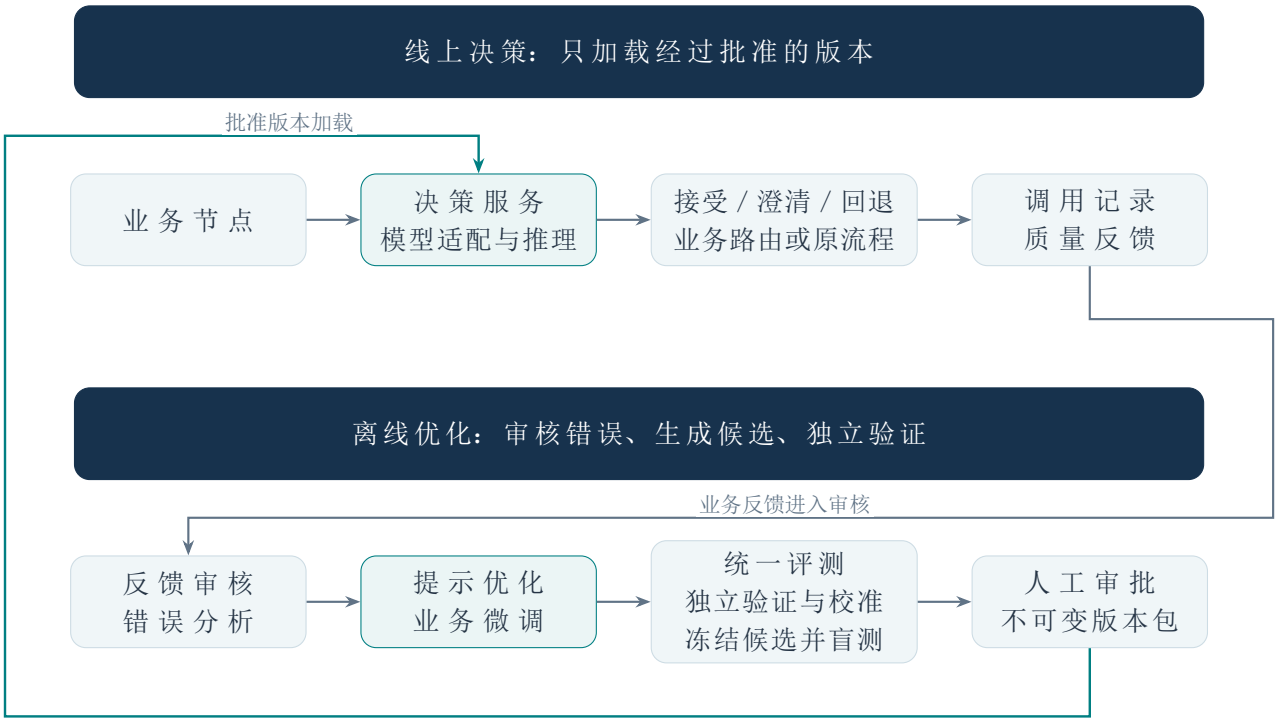


图 3　总体架构：线上执行与离线优化分离，版本包连接两侧

核心组件及其职责如下：

表 8:系统组件与职责分工

组件	主要职责
任务与数据管理	保存业务类别、输入要求、标注与数据划分，固定评测依据
决策服务与模型适配	接入候选模型，统一结构化结果，处理超时与后端差异
提示优化器	分析允许查看的错误，提出并比较提示候选
微调执行器	基于审核数据与固定模板运行训练实验
评测与版本管理	计算质量、成本和时延，记录血缘，管理发布与回退

这些组件可以先通过配置文件、批处理脚本、离线评测工具和轻量服务实现，不要求建设完整训练平台。候选模型可从 Kev、Laya、D3-Flash 等选择，中文效果、描述输入能力、训练支持和许可需逐一核实；规则与轻量分类器也应纳入对照。

线上调用只需提供任务标识和业务输入；类别描述、模型、阈值等由服务端版本包确定，避免调用方随意改变任务含义。

5　核心实现方案

5.1　业务节点如何替换

以意图识别为例，调用过程分为四步：

1. **准备输入**：提取当前问题和决定意图所需的前文，保留必要产品、渠道等授权信息。

2. **执行判断**：模型适配层将任务定义转为后端支持的格式，获取类别及原始分数。
3. **应用策略**：根据输入完整性、支持范围及校准后的接受条件，返回接受、澄清、回退或错误状态。
4. **记录结果**：关联请求、任务版本、模型/提示版本、输出、耗时、费用与回退原因，供评测和追踪。

不同模型的原始分数含义可能不同，应分别保留并校准，不能直接混用。模型给出较高分数，也不能保证输入属于支持范围或业务结果一定正确。

对“什么时候到?”这样的信息缺失，优先澄清；对超时、输入超限或不可靠结果，按策略回到原流程。决策与回退共用总截止时间，避免增加不可控等待。回退大模型的输出同样需要评测。

5.2 提示优化闭环如何运行

提示优化固定模型权重和业务类别含义，只调整判断指令、类别描述、包含/排除说明及允许的示例。

例如，初始类别描述为：

类别描述示例

退款到账问题。

如果训练池中反复出现退款与商户结算混淆，优化器可以提出：

类别描述示例

查询已发起的消费者退款何时到账或当前进度；不包含商户收款结算，也不包含尚未发起的退款申请。

实现时，优化器读取经审核的训练错误和混淆统计，提出少量候选，并说明改动与预期解决的问题。执行器检查类别集合、字段、长度和示例来源，再在固定开发集上比较初始版本、当前最优与新候选。

只有满足质量约束且产生有效收益的候选才被保留；连续无改善或达到调用费用、轮次、时间上限即停止。优化器不能修改类别定义、标签或评测程序，关键语义变化需人工审查。

该闭环仅适用于支持指令或类别描述输入的后端。固定标签分类头不能因为修改外部描述就自动获得能力提升。

5.3 业务微调闭环如何运行

微调解决的是模型对业务表达的稳定识别能力不足，不能代替输入修复和标签治理。

表 9:典型错误现象与优先处理方式

错误现象	优先处理
缺少前文，无法确定“到账”指什么	补充上下文或澄清
同类样本标注不一致、类别重叠	修正规范并仲裁标签
类别基本正确，但接受与回退不合理	校准分数和调整策略
描述已明确，仍稳定误判业务术语或口语	补充真实标注，比较微调

续下页

错误现象	优先处理
输入被截断或超过模型长度限制	调整输入方案或更换后端

进入微调后，先冻结任务与提示，按错误类型提出补数需求。新数据完成授权、脱敏、标注与去重后，使用批准的训练模板生成少量配置，在限定 GPU 时间和候选数量内执行。

训练方式以所选模型支持为准，可比较决策头、适配器或其他成熟微调方式，不假设所有后端都支持同一种 LoRA。除困难样本外，还需保留日常分布数据，防止局部提升伴随通用问题退化。

训练完成后，与未微调版本使用同样数据、输入和提示比较，并检查不同随机种子的稳定性。微调无收益则保留原版本，不强推训练产物。

5.4 两条闭环如何协同

初期先固定模型优化提示，再固定任务与入围提示比较微调。后续可以交替运行，但每次应明确主要改动，避免同时修改提示、训练数据和阈值，无法解释收益来源。

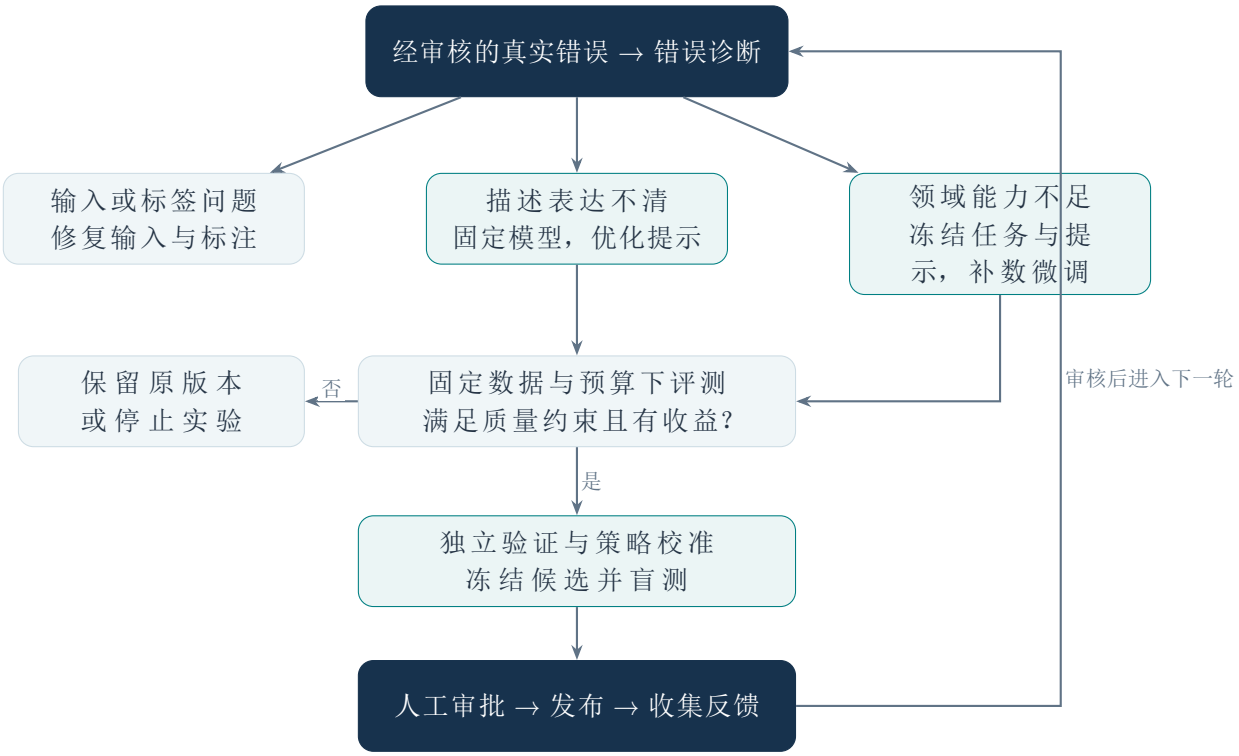


图 4　双闭环协同：按错误成因选择优化路径，验证收益后发布

最后一条反馈边表示发布后继续采集业务反馈，须经审核才能进入下一轮；不表示模型会在线自动训练或直接改写生产配置。

5.5 评测、版本与运行保障

任务规范、数据、模型、提示、输入处理、校准与接受策略共同组成一个版本包。实验记录父版本、改进假设、配置、指标及费用；上线时整包切换，异常时整包回退。

最终候选通过离线验收后，先做不改变业务结果的影子验证，再经批准灰度。监控关键类别错误、接受覆盖率、回退率、超时、成本和输入分布变化；质量或运行指标触发预设条件时暂停新版本。

数据、训练、优化器和评测分别授权；训练只运行批准模板。业务语义变更与生产发布保留人审，决策结果不直接授权退款、资金操作或风控处置。

6 效果验证方案

6.1 验证要回答的问题

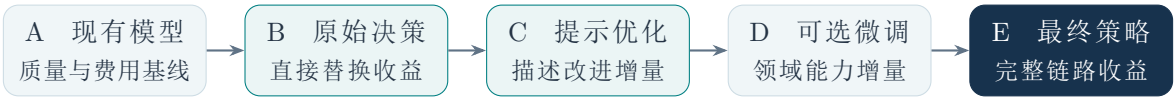


图 5 实验递进关系；E 使用开发与验证阶段选定的候选，D 可按条件开展

验证围绕三件事展开：基础替换是否值得，双闭环是否带来增量，加入回退后的完整业务链路是否仍有收益。

表 10:决策模型优化对照组设置

对照组	方案	主要验证内容
A	当前生成式大模型与现有提示	现有质量、费用和时延
B	原始决策模型与初始描述	直接替换收益
C	B + 提示优化	提示优化的增量
D	优化提示 + 业务微调	在 C 基础上是否进一步改善
E	入围候选 + 接受/澄清/回退策略	最终业务链路表现

A/B/C 为基础对照；D 在具备有效数据和训练条件时开展。若要单独归因微调贡献，可增加“初始描述 + 微调”消融组；也可让现有大模型获得同等提示优化预算，检验收益是否主要来自描述改进。

E 应评估经过开发/验证阶段选定的候选，不能在盲测中反复挑选冠军。所有方案使用相同业务语义和必要上下文。

6.2 测试数据如何准备

以真实、人工标注的业务问题为主，覆盖正常表达、易混淆类别、多轮指代、口语与错别字、未知意图、信息不足和多意图。类别不均衡时，同时保留真实分布集和困难集，分别报告。

训练/错误分析、搜索开发、独立验证、校准和最终盲测按用途隔离；同一会话、事件和近重复样本不能跨集合。优化器只查看允许的数据，盲测不用于生成候选或调阈值。

数据规模根据类别覆盖与要证明的差异确定，不预先用固定条数保证效果。可先用小批样本完善标注边界，再扩展独立评测；合成数据可辅助训练，不充当真实业务验收数据。

6.3 离线同题对照

对各组重放相同问题，记录预测结果、耗时和费用，并对错误按类别和场景拆分。

表 11:离线评测指标及其用途

维度	核心指标	目的
分类质量	Accuracy、Macro-F1、各类召回/精确率	避免整体分数掩盖关键类别退化
接受策略	自动接受覆盖率、接受部分错误率	同时衡量“处理多少”和“处理得多可靠”
性能	p50/p95、吞吐、超时率	判断实际并发下是否提速
费用	单节点费用、完整任务费用	区分节点节省与总体节省

使用真实中文长度、类别数、设备和并发，区分冷启动与稳定运行；同时纳入现有模型的缓存和批处理条件。对质量差值报告合适的区间，按会话分组进行配对分析；较小提升需足够样本支撑，训练与推理随机性分别检查。

未知输入和关键业务错误单独观察，不能只筛选高置信度成功样本展示准确率。

6.4 完整业务链路验证

节点评测通过后，还要验证下游结果，防止“分类更便宜，业务反而变差”。

表 12:完整业务链路场景与下游验证

场景	下游验证方式
意图识别	检查最终路由正确率、误转、用户纠正和转人工情况
是否改写	比较原始与改写后检索的关键证据召回、回答质量及完整任务费用
片段筛选	检查关键证据是否误删、回答是否有依据和完整，并与现有 reranker 比较

先通过影子流量做同题比较，再按会话固定分组进行受控灰度。影子双跑的额外开销单列为实验费用。线上没有投诉不等于正确，应结合抽样审核及可信反馈评估。

6.5 成本口径与验收结论

成本至少包括决策推理、原流程回退、仍需执行的生成/检索，以及新增部署运维；标注、提示搜索、训练和验收费用按约定周期摊销。

完整成本口径

$$\text{每成功任务总成本} = \frac{\text{全部任务总成本}}{\text{成功任务数}}$$

回退和失败任务的支出不能排除。分别报告试点规模与预期业务量下的成本；低流量时，自部署固定费用可能抵消推理节省。

为便于比较，按 A–E 对照组分别报告分类质量及区间、关键类别召回、自动接受覆盖率与接受部分错误率。

完整链路同时报告每成功任务生成式调用次数（含回退）、回答模型输入 token 均值与 p95、完整链路 p95、每成功任务总成本、回退率与回退费用。微调条件不具备时标记“不适用”；尚未完成实测的指标标记“待测”。

各项质量门槛、关键类别召回下限、覆盖率要求及 SLA 应在查看候选结果前确定。**先满足质量约束，再比较成本和时延。**降本提速比例以实测为准；样本不足时仅报告观察结果，不宣称已证明生产收益。

7 预期价值与适用边界

本方案的价值有三个层面：通过适配判断任务的模型减少不必要的生成开销；用真实错误推动可验证的持续改进；复用任务定义、模型适配和评测能力，降低后续节点接入成本。

适合优先尝试的节点应具有明确输出、可获得可靠标签、稳定业务边界和足够调用量。开放式生成、复杂推理或缺乏必要上下文的任务，不宜仅靠分类替换。

项目创新重点不是单独使用提示优化或微调，而是把支付业务边界、双闭环优化、质量约束和完整成本核算连起来，形成从真实错误到可追溯发布版本的链路。

如果实测发现回退率过高、质量不达标或总成本无改善，应只替换有效节点、保留原模型，或停止相应优化。有效结论也可以是“提示优化有用，微调暂时无收益”。

候选能力核查入口： Kev、Laya 微调、D3-Flash。链接沿用原稿，实施前重新核实版本、训练方式和许可。